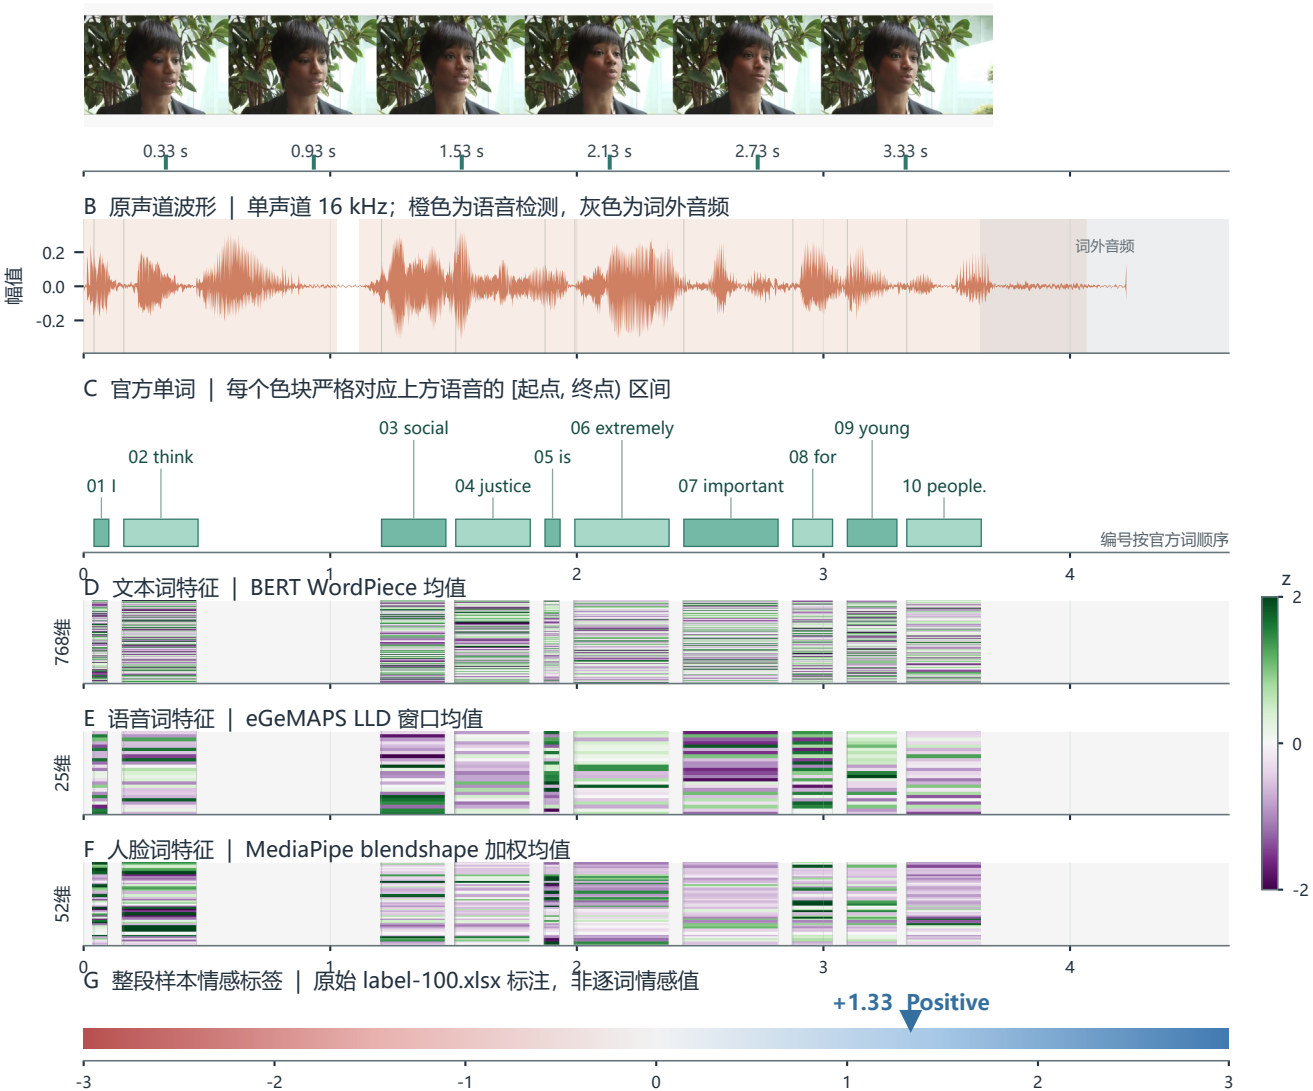
图1c 多模态视频片段的逐词时间对齐：正向样本

-THoVjtIkeU_2 · 原视频 4.64 s · 官方文本 10 词 · 有效对齐 10/10 词



词边界来自 WhisperX 的实际语音对齐；文本保持官方原词。三行特征共用词时间，灰白间隙表示原素材中的词间空白。

特征热图按本片段每个通道在词间标准化，仅用于显示；原始 768/25/52 维数值保存在 NPZ。视频帧为原视频抽样。

A–F 共用原音视频时间轴（秒）；时间戳为自动估计，逐词原始帧和特征行号可在配套 CSV 与试听页面核对。