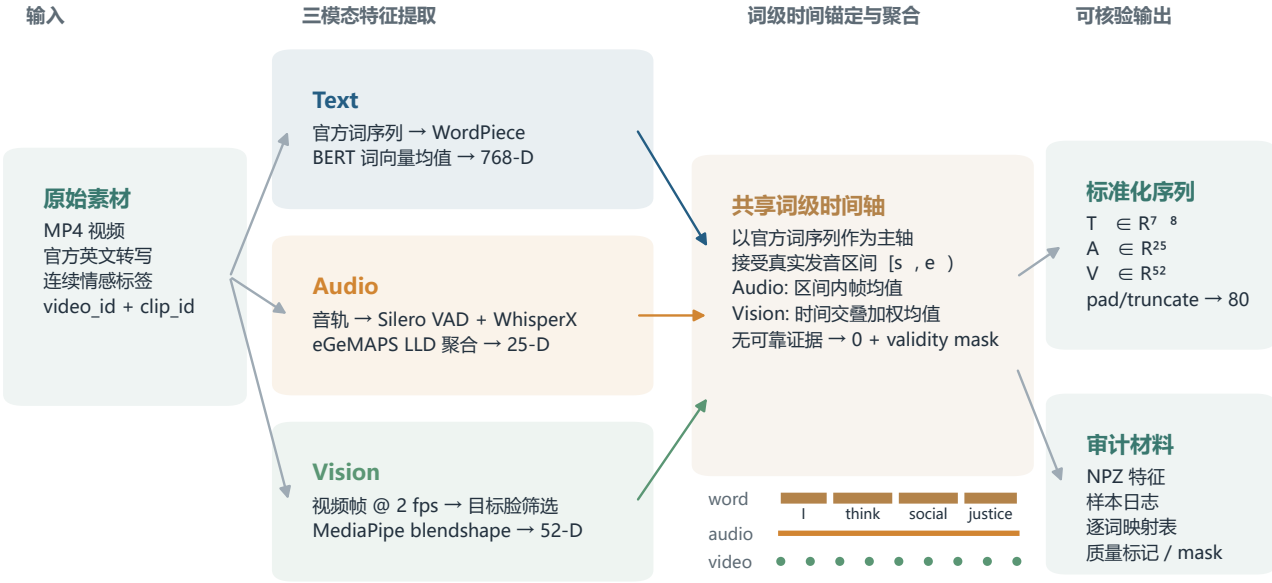

输入
三模态特征提取
词级时间锚定与聚合
可核验输出
原始素材
MP4 视频
官方英文转写
连续情感标签
video_id + clip_id
Text
官方词序列 → WordPiece
BERT 词向量均值 → 768-D
Audio
音轨 → Silero VAD + WhisperX
eGeMAPS LLD 聚合 → 25-D
Vision
视频帧 @ 2 fps → 目标脸筛选
MediaPipe blendshape → 52-D
共享词级时间轴
以官方词序列作为主轴
接受真实发音区间［s ，e ）
Audio: 区间内帧均值
Vision: 时间交叠加权均值
无可靠证据 → 0 + validity mask
word
I
think
social
justice
audio
video
标准化序列
T ∈ R7 8
A ∈ R25
V ∈ R52
pad/truncate → 80
审计材料
NPZ 特征
样本日志
逐词映射表
质量标记 / mask